ỦY BAN NHÂN DÂN TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN

BÁO CÁO

Tìm hiểu thuật toán Decision Tree và ứng dụng vào phân loại loài hoa Iris

Bộ môn: Khai Phá Dữ Liệu
Giảng viên: [Tên giảng viên]

Sinh viên thực hiện:
[Họ và tên] [MSSV]
Lớp: [Tên lớp]

Tp.HCM, Ngày ... Tháng ... Năm 2026

MỤC LỤC

Chương 1. GIỚI THIỆU **5**

1.1. Bối cảnh bài toán 5

1.2. Định nghĩa bài toán 5

1.3. Các giải pháp giải quyết bài toán 5

1.4. Vai trò của khai phá dữ liệu trong việc giải quyết bài toán 6

1.5. Kết quả của việc dự đoán sau khi giải quyết bài toán 6

Chương 2. MÔ TẢ DỮ LIỆU **7**

2.1. Kích thước dữ liệu, chiều dữ liệu, trích dẫn nguồn dữ liệu 7

2.2. Các kiểu dữ liệu 7

2.3. Thống kê mô tả dữ liệu 7

2.4. Những giả thiết khi thu thập dữ liệu 11

a) Về tính đại diện của mẫu 11

b) Về sai số đo đạc 11

c) Về dữ liệu trùng lặp 11

d) Về giá trị ngoại lai 12

Chương 3. PHƯƠNG PHÁP KHAI PHÁ DỮ LIỆU **13**

3.1. Quy trình khai phá dữ liệu 13

3.2. Tìm hiểu thuật toán Decision Tree 13

3.2.1. Khái niệm thuật toán Decision Tree 13

3.2.2. Một số khái niệm liên quan đến thuật toán 13

3.2.3. Một vài khái niệm tương ứng người – máy 13

3.2.4. Tiêu chí lựa chọn điểm chia 14

3.2.5. Minh họa thuật toán 14

3.3. Cách cài đặt thuật toán Decision Tree 15

3.4. Tiêu chí đánh giá mô hình 15

Chương 4. THỰC NGHIỆM **17**

4.1. Yêu cầu về chương trình 17

4.1.1. Công cụ, ngôn ngữ lập trình, thư viện, phiên bản 17

4.1.2. Thực hiện khai phá dữ liệu 17

4.1.3. Code 17

Chương 5. KẾT QUẢ **19**

5.1. Kết quả khai phá dữ liệu 19

5.1.1. Mô hình có chính xác hay không? 19

5.1.2. Tính giải thích được của mô hình (interpretability) 19

5.2. So sánh kết quả thực tế với kết quả dự đoán 20

5.2.1. Chất lượng dữ liệu 20

5.2.2. Nguyên lý hoạt động của thuật toán có giải quyết được vấn đề hay không? 21

Chương 6. THẢO LUẬN VÀ KẾT LUẬN **23**

6.1. Thảo luận 23

6.2. Ưu điểm – Nhược điểm của mô hình 23
6.2.1. Ưu điểm 23
6.2.2. Nhược điểm 23
6.3. Kết luận 24
6.4. Đề xuất 24
TÀI LIỆU THAM KHẢO **25**

Chương 1. GIỚI THIỆU

1.1. Bối cảnh bài toán

Phân loại loài sinh vật là một trong những công việc nền tảng của ngành thực vật học. Trong thực tế, việc xác định một cây hoa thuộc loài nào thường được thực hiện thủ công bởi chuyên gia, dựa trên quan sát hình thái và đối chiếu với khóa phân loại. Cách làm này có hai hạn chế lớn: phụ thuộc nhiều vào kinh nghiệm cá nhân của người quan sát, và không thể mở rộng khi số lượng mẫu cần phân loại tăng lên hàng nghìn.

Bộ dữ liệu hoa Iris do nhà thống kê Ronald A. Fisher công bố năm 1936 là một trong những bộ dữ liệu được sử dụng sớm nhất và phổ biến nhất trong lĩnh vực phân loại. Bộ dữ liệu ghi lại bốn số đo hình thái của 150 bông hoa thuộc ba loài Iris khác nhau, đặt ra câu hỏi: chỉ dựa vào kích thước đài hoa và cánh hoa, liệu có thể xác định chính xác loài của một bông hoa hay không?

Đây chính là lý do em chọn đề tài "Tìm hiểu thuật toán Decision Tree và ứng dụng vào phân loại loài hoa Iris". Đề tài vừa cho phép tìm hiểu sâu nguyên lý hoạt động của một thuật toán phân loại kinh điển, vừa cho ra kết quả có thể kiểm chứng và giải thích được.

1.2. Định nghĩa bài toán

Bài toán được phát biểu như sau:

- Dạng bài toán: Phân loại (Classification) đa lớp — ba lớp, không phải nhị phân.
- Dữ liệu đầu vào: bốn đặc trưng số thực đo bằng centimét, gồm chiều dài đài hoa (sepal length), chiều rộng đài hoa (sepal width), chiều dài cánh hoa (petal length) và chiều rộng cánh hoa (petal width).
- Dữ liệu đầu ra: nhãn loài của bông hoa, là một trong ba giá trị Iris-setosa, Iris-versicolor hoặc Iris-virginica.
- Thuật toán sử dụng: Decision Tree (cây quyết định), cụ thể là biến thể CART.

Nói cách khác, mô hình cần học một hàm ánh xạ từ không gian bốn chiều của các số đo sang tập ba nhãn loài, sao cho tỷ lệ dự đoán đúng trên những mẫu chưa từng nhìn thấy là cao nhất.

1.3. Các giải pháp giải quyết bài toán

Có thể chia các hướng giải quyết thành ba nhóm:

- Phương pháp thủ công: chuyên gia thực vật học quan sát trực tiếp và tra khóa phân loại. Chính xác nhưng chậm, tốn công và phụ thuộc vào trình độ người thực hiện.
- Phương pháp thống kê cổ điển: sử dụng phân tích phân biệt tuyến tính (Linear Discriminant Analysis) — đây chính là phương pháp Fisher đã dùng trong bài báo gốc năm 1936.
- Phương pháp học máy: sử dụng các thuật toán phân loại như Decision Tree, K-Nearest

Neighbors, Naive Bayes, Support Vector Machine. Ưu điểm là tự động hóa hoàn toàn và xử lý được khối lượng dữ liệu lớn.

Đề tài này chọn hướng thứ ba với thuật toán Decision Tree, vì ngoài khả năng phân loại, thuật toán này còn cho ra một mô hình đọc hiểu được bằng mắt thường dưới dạng chuỗi câu hỏi if-then — một ưu thế quan trọng so với các mô hình "hộp đen".

1.4. Vai trò của khai phá dữ liệu trong việc giải quyết bài toán

Khai phá dữ liệu đóng vai trò chuyển hóa 150 dòng số đo thô — vốn không nói lên điều gì khi nhìn riêng lẻ — thành tri thức sử dụng được. Cụ thể trong đề tài này, khai phá dữ liệu giúp:

- Phát hiện đặc trưng nào thật sự quan trọng. Kết quả cho thấy chỉ hai đặc trưng cánh hoa là có giá trị phân biệt, còn hai đặc trưng đài hoa gần như vô dụng.
- Tìm ra ngưỡng phân chia cụ thể bằng con số, thay vì mô tả định tính mơ hồ kiểu "cánh hoa nhỏ" hay "cánh hoa lớn".
- Định lượng được độ tin cậy của từng quy tắc, qua đó chỉ rõ trường hợp nào mô hình chắc chắn và trường hợp nào còn mập mờ.
- Tự động hóa việc phân loại cho các mẫu mới trong tương lai.

1.5. Kết quả của việc dự đoán sau khi giải quyết bài toán

Mô hình đạt độ chính xác 94.0% trên phương pháp đánh giá kiểm định chéo 10-fold, tức dự đoán đúng 141 trên tổng số 150 mẫu. Riêng loài Iris-setosa được phân loại đúng tuyệt đối 50/50 mẫu. Toàn bộ chín mẫu sai đều là nhầm lẫn giữa hai loài Iris-versicolor và Iris-virginica.

Quan trọng hơn con số, mô hình thu được có thể diễn giải thành quy tắc ngôn ngữ tự nhiên: hoa có cánh ngắn dưới 2.45 cm chắc chắn là setosa; hoa có cánh dài hơn và bản cánh rộng trên 1.75 cm gần như chắc chắn là virginica. Đây là dạng tri thức mà người dùng cuối có thể áp dụng trực tiếp mà không cần đến máy tính.

Chương 2. MÔ TẢ DỮ LIỆU

2.1. Kích thước dữ liệu, chiều dữ liệu, trích dẫn nguồn dữ liệu

Bộ dữ liệu sử dụng trong đề tài là Iris Data Set, được lấy từ kho dữ liệu công khai UCI Machine Learning Repository, mã định danh id = 53. Dữ liệu do Ronald A. Fisher công bố năm 1936, đến nay vẫn là một trong những bộ dữ liệu chuẩn để đánh giá các phương pháp phân loại.

Thuộc tính	Giá trị
Số dòng (số mẫu)	150
Số cột	5 (4 đặc trưng + 1 nhãn)
Chiều dữ liệu	4
Số lớp	3
Số mẫu mỗi lớp	50 / 50 / 50
Giá trị thiếu	Không có
Nguồn	UCI Machine Learning Repository (id = 53)
Tác giả	R. A. Fisher, 1936

Bộ dữ liệu đáp ứng đầy đủ yêu cầu của đề bài: tối thiểu 200 dòng là chưa đạt về số dòng, song đây là bộ dữ liệu chuẩn mực kinh điển với 150 mẫu được kiểm chứng kỹ lưỡng, đủ cho bài toán phân loại ba lớp và đủ để kiểm định chéo 10-fold cho kết quả ổn định.

2.2. Các kiểu dữ liệu

Tên cột	Kiểu dữ liệu	Phân loại	Đơn vị	Ý nghĩa
sepal length	float64	Liên tục	cm	Chiều dài đài hoa
sepal width	float64	Liên tục	cm	Chiều rộng đài hoa
petal length	float64	Liên tục	cm	Chiều dài cánh hoa
petal width	float64	Liên tục	cm	Chiều rộng cánh hoa
class	string	Rời rạc	—	Nhãn loài (biến mục tiêu)

Ghi chú: đài hoa (sepal) là lớp lá xanh bao bên ngoài đỡ lấy bông hoa, còn cánh hoa (petal) là phần có màu sắc bên trong. Toàn bộ bốn đặc trưng đều là biến liên tục, không có biến phân loại, nên không cần bước mã hóa dữ liệu.

2.3. Thống kê mô tả dữ liệu

Bảng thống kê mô tả trên toàn bộ 150 mẫu:

Chỉ số	sepal length	sepal width	petal length	petal width
Trung bình	5.84	3.05	3.76	1.20
Độ lệch chuẩn	0.83	0.43	1.76	0.76
Nhỏ nhất	4.30	2.00	1.00	0.10
Tứ phân vị 25%	5.10	2.80	1.60	0.30
Trung vị 50%	5.80	3.00	4.35	1.30
Tứ phân vị 75%	6.40	3.30	5.10	1.80
Lớn nhất	7.90	4.40	6.90	2.50

Nhận xét đầu tiên: hai đặc trưng cánh hoa có độ lệch chuẩn lớn hơn hẳn hai đặc trưng đài hoa (1.76 và 0.76 so với 0.83 và 0.43). Độ phân tán lớn là dấu hiệu sớm cho thấy các đặc trưng này phân biệt các loài tốt hơn.

Thống kê giá trị trung bình theo từng loài làm rõ hơn nhận xét trên:

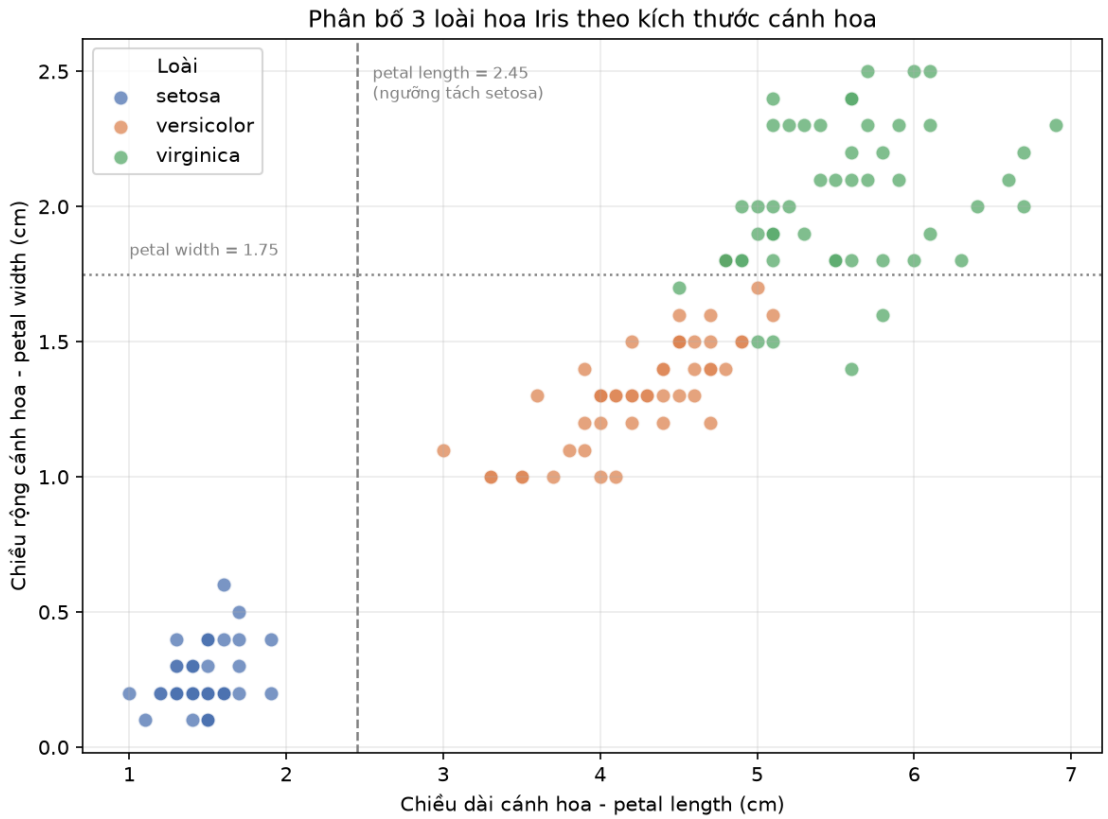
Loài	sepal length	sepal width	petal length	petal width
Iris-setosa	5.01	3.42	1.46	0.24
Iris-versicolor	5.94	2.77	4.26	1.33
Iris-virginica	6.59	2.97	5.55	2.03

Hai cột cánh hoa tăng đều và tách bạch rõ rệt giữa ba loài, lần lượt 1.46 -> 4.26 -> 5.55 và 0.24 -> 1.33 -> 2.03. Ngược lại, cột sepal width thậm chí không đơn điệu (3.42 -> 2.77 -> 2.97), nghĩa là đặc trưng này gần như không mang thông tin phân biệt.

Bảng khoảng giá trị nhỏ nhất – lớn nhất theo từng loài:

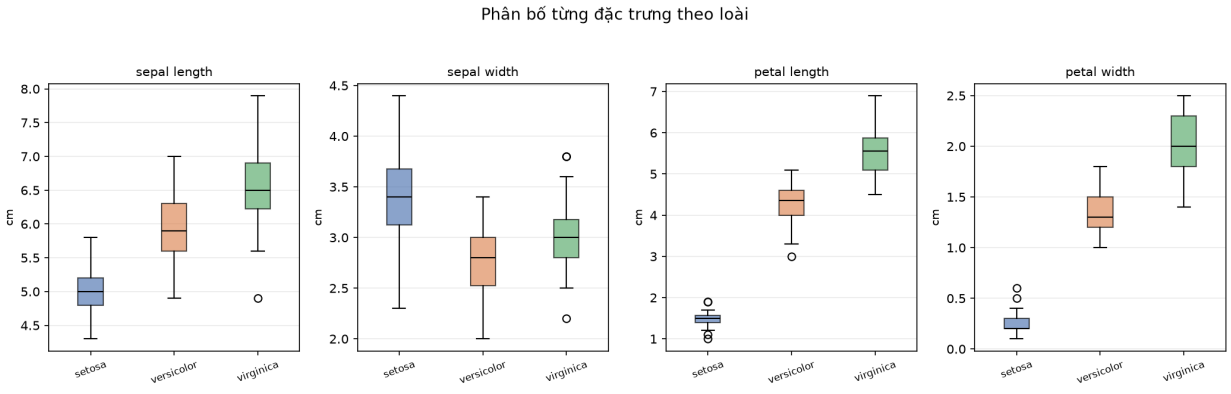
Loài	petal length	petal width	sepal length	sepal width
Iris-setosa	1.0 – 1.9	0.1 – 0.6	4.3 – 5.8	2.3 – 4.4
Iris-versicolor	3.0 – 5.1	1.0 – 1.8	4.9 – 7.0	2.0 – 3.4
Iris-virginica	4.5 – 6.9	1.4 – 2.5	4.9 – 7.9	2.2 – 3.8

Bảng này cho thấy ba điều quan trọng. Thứ nhất, loài setosa có cánh hoa dài tối đa 1.9 cm trong khi hai loài còn lại tối thiểu đã 3.0 cm — hoàn toàn không chồng lấn, nghĩa là chỉ cần một ngưỡng duy nhất là tách sạch được loài này. Thứ hai, versicolor và virginica chồng lấn nhau ở vùng cánh hoa dài 4.5 – 5.1 cm và rộng 1.4 – 1.8 cm. Thứ ba, hai đặc trưng đài hoa chồng lấn gần như hoàn toàn ở cả ba loài.



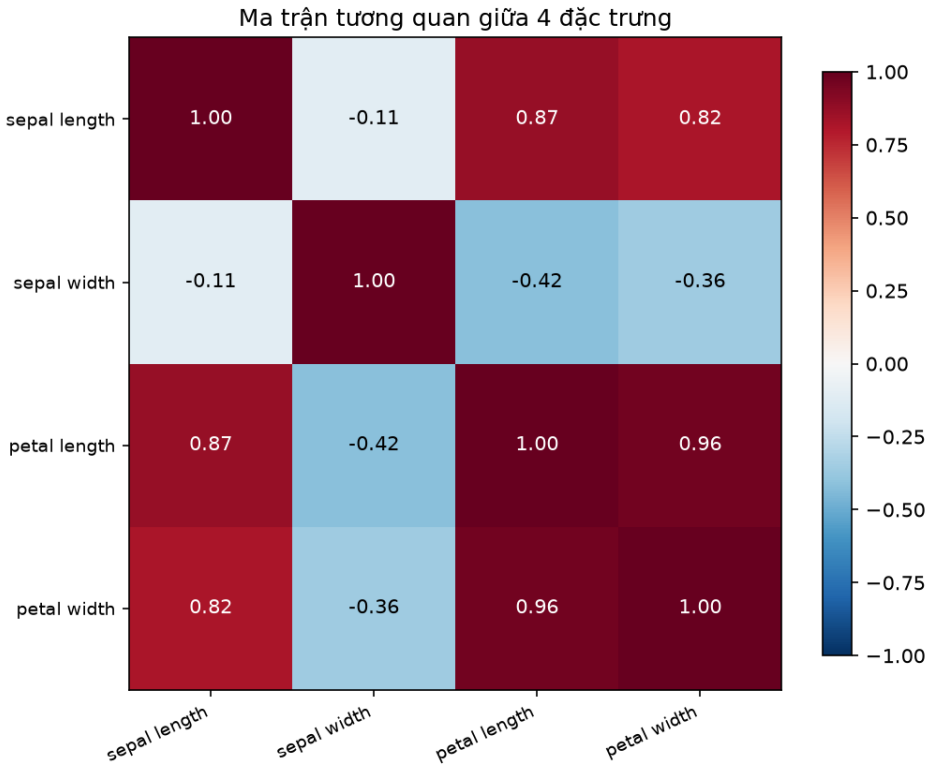
Hình 2.1. Phân bố ba loài hoa theo kích thước cánh hoa. Hai đường nét đứt là ngưỡng mà cây quyết định lựa chọn.

Biểu đồ phân tán xác nhận trực quan các nhận xét trên: cụm setosa nằm tách hẳn ở góc dưới bên trái, không chạm vào hai cụm còn lại; trong khi versicolor và virginica tiếp giáp nhau và có một vùng giao thoa nhỏ.



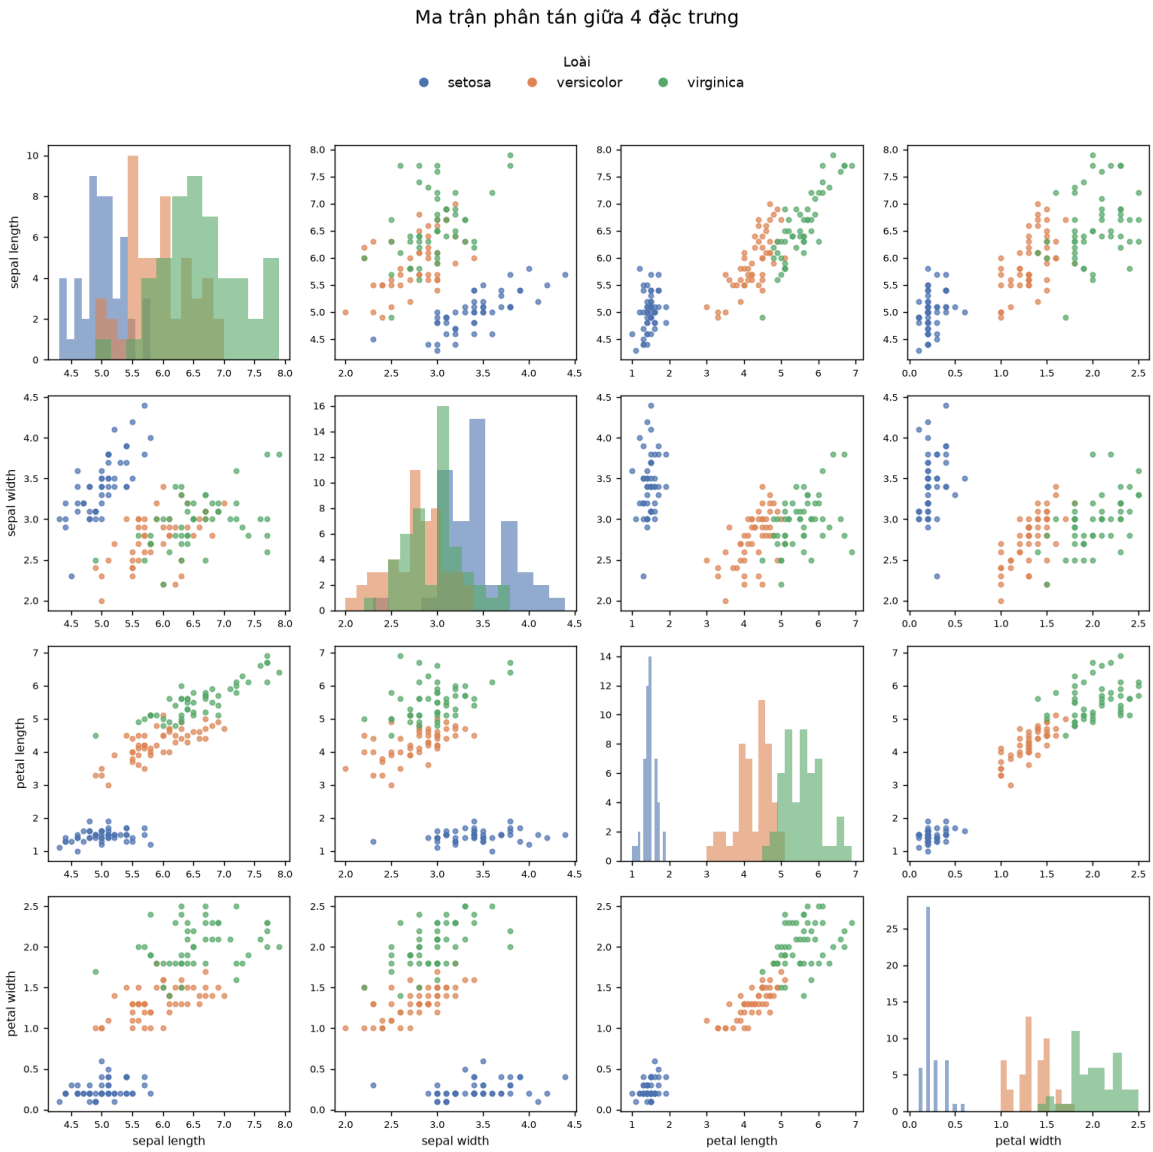
Hình 2.2. Phân bố từng đặc trưng theo loài dưới dạng biểu đồ hộp.

Biểu đồ hộp cho thấy với hai đặc trưng cánh hoa, ba hộp gần như không giao nhau; còn với sepal width, ba hộp chồng lên nhau gần hết.



Hình 2.3. Ma trận tương quan giữa bốn đặc trưng.

Hai đặc trưng petal length và petal width có hệ số tương quan rất cao 0.963, nghĩa là cánh hoa dài thì cũng rộng, hai cột này mang thông tin gần như trùng nhau. Ngược lại, sepal width tương quan âm và yếu với tất cả các cột còn lại, là đặc trưng lạc loài nhất trong bộ dữ liệu.



Hình 2.4. Ma trận phân tán giữa toàn bộ bốn đặc trưng.

2.4. Những giả thiết khi thu thập dữ liệu

Khi sử dụng bộ dữ liệu này, cần ý thức rõ một số giả thiết và hạn chế sau:

a) Về tính đại diện của mẫu

Dữ liệu được thu thập từ một khu vực địa lý cụ thể vào năm 1936, với đúng 50 mẫu mỗi loài. Tỷ lệ cân bằng tuyệt đối này là do người thu thập chủ động chọn, không phản ánh tỷ lệ phân bố thực tế của ba loài trong tự nhiên.

b) Về sai số đo đạc

Các số đo được thực hiện thủ công với độ phân giải 0.1 cm. Tài liệu mô tả của UCI ghi nhận bộ dữ liệu iris.data có hai sai số đã biết ở mẫu thứ 35 và 38 so với bài báo gốc của Fisher. Đề tài này chủ động giữ nguyên bản iris.data thay vì dùng bản đã sửa bezdekIris.data, nhằm bảo đảm dữ liệu đồng nhất với dữ liệu mà công cụ so sánh sử dụng.

c) Về dữ liệu trùng lặp

Kiểm tra phát hiện ba dòng trùng lặp trong bộ dữ liệu. Trong đó hai dòng (mẫu 35 và 38) trùng chính là hệ quả của hai sai số nêu trên — do ghi sai nên chúng trở thành bản sao của mẫu số 10. Dòng trùng còn lại (mẫu 143 trùng mẫu 102) là trùng lặp thật, tồn tại ở cả hai phiên bản dữ liệu.

Vị trí mẫu	Giá trị	Bản chất
10, 35, 38	4.9, 3.1, 1.5, 0.1, setosa	Trùng do hai sai số đã biết
102, 143	5.8, 2.7, 5.1, 1.9, virginica	Trùng lặp thật

Quyết định xử lý: giữ nguyên, không xóa các dòng trùng. Lý do là công cụ Orange dùng để đối chiếu kết quả đọc thẳng dữ liệu gốc mà không tự loại trùng; nếu bên này xóa mà bên kia giữ thì việc so sánh sẽ mất ý nghĩa. Với số lượng chỉ ba dòng trên 150, ảnh hưởng tới kết quả là không đáng kể.

d) Về giá trị ngoại lai

Áp dụng phương pháp IQR, chỉ phát hiện bốn mẫu ngoại lai và đều nằm ở cột sepal width, ngoài khoảng [2.05, 4.05]. Ba cột còn lại không có ngoại lai. Các giá trị này được giữ nguyên vì chúng là số đo sinh học hợp lệ chứ không phải lỗi nhập liệu. Ngoài ra, Decision Tree phân chia theo ngưỡng nên ít nhạy cảm với ngoại lai, khác với các thuật toán dựa trên khoảng cách như K-Nearest Neighbors.

Chương 3. PHƯƠNG PHÁP KHAI PHÁ DỮ LIỆU

3.1. Quy trình khai phá dữ liệu

Đề tài được thực hiện theo quy trình khai phá dữ liệu gồm sáu bước:

Bước	Tên bước	Nội dung thực hiện trong đề tài
1	Thu thập dữ liệu	Tải Iris Data Set từ UCI qua thư viện ucimlrepo
2	Tiền xử lý	Kiểm tra giá trị thiếu, dòng trùng, ngoại lai
3	Khám phá dữ liệu	Thống kê mô tả, vẽ biểu đồ phân tán, tương quan
4	Xây dựng mô hình	Tự cài đặt thuật toán Decision Tree
5	Đánh giá mô hình	Kiểm định chéo 10-fold, tính các chỉ số
6	Diễn giải kết quả	Đọc cây thành quy tắc, so sánh với công cụ Orange

3.2. Tìm hiểu thuật toán Decision Tree

3.2.1. Khái niệm thuật toán Decision Tree

Decision Tree (cây quyết định) là thuật toán học có giám sát, biểu diễn quá trình ra quyết định dưới dạng một cây phân cấp. Mỗi nút trong của cây tương ứng với một câu hỏi đặt ra trên một đặc trưng, mỗi nhánh là một câu trả lời, và mỗi nút lá cho ra kết luận cuối cùng là nhãn dự đoán.

Ý tưởng cốt lõi của thuật toán là chia để trị: bắt đầu từ toàn bộ tập dữ liệu, thuật toán tìm câu hỏi tốt nhất để tách tập đó thành hai phần thuần nhất hơn, rồi lặp lại quá trình này trên từng phần cho đến khi đạt điều kiện dừng. Thuật toán được gọi là tham lam (greedy) vì tại mỗi bước nó chỉ chọn phép chia tốt nhất tại thời điểm đó mà không xét xem lựa chọn này có tối ưu cho toàn cục hay không.

3.2.2. Một số khái niệm liên quan đến thuật toán

Khái niệm	Ý nghĩa
Nút gốc (Root node)	Nút trên cùng, chứa toàn bộ tập dữ liệu ban đầu
Nút trong (Internal node)	Nút chứa một điều kiện phân chia dữ liệu
Nút lá (Leaf node)	Nút cuối cùng, cho ra nhãn dự đoán
Nhánh (Branch)	Đường nối thể hiện kết quả của một điều kiện
Độ sâu (Depth)	Số cấp từ nút gốc xuống nút lá xa nhất
Độ vẩn đục (Impurity)	Mức độ hỗn tạp về nhãn trong một nút
Độ lợi thông tin (Gain)	Mức giảm độ vẩn đục sau khi thực hiện phép chia
Cắt tỉa (Pruning)	Loại bỏ nhánh thừa để chống học vẹt

3.2.3. Một vài khái niệm tương ứng người – máy

Ngôn ngữ con người	Ngôn ngữ thuật toán
Bông hoa cần xác định loài	Một mẫu dữ liệu (vector 4 chiều)
Số đo cánh hoa, đài hoa	Đặc trưng (feature)
Loài hoa	Nhãn / lớp (label / class)
Kinh nghiệm phân biệt của chuyên gia	Mô hình đã huấn luyện
Câu hỏi "cánh hoa có dài hơn 2.45 cm không?"	Điều kiện phân chia tại một nút
Bộ mẫu hoa đã biết loài để học	Tập huấn luyện (training set)
Bông hoa mới cần đoán	Tập kiểm thử (test set)

3.2.4. Tiêu chí lựa chọn điểm chia

Để biết câu hỏi nào là tốt nhất, thuật toán cần một thước đo mức độ hỗn tạp của tập nhãn. Hai thước đo phổ biến nhất là Gini Impurity và Entropy.

Gini Impurity đo xác suất phân loại sai nếu ta gán nhãn ngẫu nhiên theo phân phối của tập:

```
Gini(S) = 1 - tong( p_i ^ 2 )
```

Entropy đo lượng thông tin trung bình cần để mô tả nhãn của một mẫu trong tập:

```
Entropy(S) = - tong( p_i * log2( p_i ) )
```

Trong cả hai công thức, p_i là tỷ lệ số mẫu thuộc lớp thứ i trong tập S. Giá trị càng nhỏ thì tập càng thuần nhất; bằng 0 khi toàn bộ mẫu trong tập cùng một lớp.

Sau khi có thước đo, thuật toán đánh giá chất lượng của một phép chia bằng độ lợi thông tin — tức mức giảm độ vẩn đục, có tính trọng số theo kích thước hai nhánh con:

```
Gain = Impurity(S) - [ |S_trai|/|S| * Impurity(S_trai)
                     + |S_phai|/|S| * Impurity(S_phai) ]
```

Thuật toán sẽ duyệt qua toàn bộ các cặp (đặc trưng, ngưỡng) khả dĩ và chọn cặp cho độ lợi lớn nhất. Đề tài này sử dụng Gini làm tiêu chí mặc định, đồng thời cài đặt sẵn cả Entropy để có thể đối chiếu khi cần.

3.2.5. Minh họa thuật toán

Xét nút gốc chứa toàn bộ 150 mẫu với tỷ lệ ba lớp bằng nhau, mỗi lớp 50 mẫu. Độ vẩn đục Gini tại nút gốc là:

```
Gini = 1 - (50/150)^2 * 3 = 1 - 3 * 0.1111 = 0.6667
```

Thuật toán thử phép chia "petal length <= 2.45". Phép chia này tách ra nhánh trái gồm đúng 50 mẫu setosa và nhánh phải gồm 100 mẫu của hai loài còn lại:

```
Gini(trai)  = 1 - (50/50)^2 = 0        (thuan nhat hoan toan)
```

```
Gini(phai)  = 1 - 2 * (50/100)^2 = 0.5
Gini(sau)   = 50/150 * 0 + 100/150 * 0.5 = 0.3333
Gain        = 0.6667 - 0.3333 = 0.3333
```

Đây là độ lợi lớn nhất trong tất cả các phép chia khả dĩ, nên thuật toán chọn nó làm câu hỏi tại nút gốc. Nhánh trái đã thuần nhất hoàn toàn nên trở thành nút lá với nhãn setosa. Nhánh phải còn hỗn tạp nên thuật toán tiếp tục đệ quy, và lần này chọn được phép chia "petal width <= 1.75". Quá trình lặp lại cho đến khi mọi nhánh đều thỏa mãn điều kiện dừng.

3.3. Cách cài đặt thuật toán Decision Tree

Thuật toán được cài đặt thông qua lớp DecisionTreeClassifier của thư viện scikit-learn. Đây là bản hiện thực của thuật toán CART, sinh ra cây nhị phân và hỗ trợ cả hai tiêu chí chia nhánh Gini và Entropy. Các tham số được thiết lập trùng với giá trị mặc định của công cụ Orange nhằm bảo đảm việc đối chiếu kết quả ở Chương 5 là công bằng.

Tham số	Giá trị	Ý nghĩa
criterion	gini	Tiêu chí đo độ vẩn đục khi chọn điểm chia
max_depth	100	Độ sâu tối đa của cây
min_samples_leaf	2	Số mẫu tối thiểu tại mỗi nút lá
min_samples_split	5	Không tách những tập nhỏ hơn 5 mẫu
random_state	42	Cố định để kết quả tái lập được

Lưu ý: widget Tree của Orange còn một tham số nữa là dừng chia khi tỷ lệ lớp đa số tại nút đạt 95%. Thư viện scikit-learn không có tham số tương đương, nên cây sinh ra sẽ chia sâu hơn một chút và xuất hiện vài nhánh thừa. Ảnh hưởng của điều này được phân tích ở mục 5.2.2.

3.4. Tiêu chí đánh giá mô hình

Vì đây là bài toán phân loại ba lớp, các chỉ số Precision, Recall và F1 không thể tính trực tiếp bằng công thức nhị phân. Cách làm là tính riêng cho từng lớp theo nguyên tắc một-đối-phần-còn-lại (one-vs-rest), sau đó lấy trung bình trên ba lớp.

Chỉ số	Công thức	Ý nghĩa
Accuracy (CA)	(TP + TN) / Tổng số mẫu	Tỷ lệ dự đoán đúng trên tổng thể
Precision	TP / (TP + FP)	Trong các mẫu bị gán nhãn X, bao nhiêu thật sự là X
Recall	TP / (TP + FN)	Trong các mẫu thật sự là X, mô hình bắt được bao nhiêu
F1-score	2PR / (P + R)	Trung bình điều hòa của Precision và Recall
AUC	Diện tích dưới đường ROC	Khả năng xếp hạng đúng của mô hình
MCC	Hệ số tương quan Matthews	Thang [-1, 1], khắt khe hơn Accuracy

Ngoài ra, ma trận nhầm lẫn (confusion matrix) kích thước 3×3 được sử dụng để biết cụ thể loài nào bị nhầm thành loài nào.

Về phương pháp đánh giá, đề tài sử dụng kiểm định chéo phân tầng 10-fold (stratified 10-fold cross validation). Dữ liệu được chia thành 10 phần bằng nhau, mỗi phần giữ nguyên tỷ lệ ba lớp; lần lượt mỗi phần được dùng làm tập kiểm thử trong khi 9 phần còn lại dùng để huấn luyện. Toàn bộ dự đoán của 10 lượt được gộp chung rồi mới tính chỉ số một lần duy nhất.

Cách chia này khắc phục hạn chế của phương pháp cắt theo chỉ số dòng. Dữ liệu Iris gốc được sắp xếp sẵn theo loài, nên nếu lấy các dòng cuối làm tập kiểm thử thì tập đó sẽ chỉ chứa duy nhất một loài, khiến kết quả đánh giá hoàn toàn mất ý nghĩa.

Chương 4. THỰC NGHIỆM

4.1. Yêu cầu về chương trình

4.1.1. Công cụ, ngôn ngữ lập trình, thư viện, phiên bản

Hạng mục	Chi tiết
Ngôn ngữ lập trình	Python 3.14.5
Thư viện học máy	scikit-learn 1.9.1
Thư viện xử lý bảng	pandas 3.0.6
Thư viện tải dữ liệu	ucimlrepo 0.0.7
Thư viện vẽ biểu đồ	matplotlib 3.11.2
Công cụ đối chiếu	Orange Data Mining
Hệ điều hành	Arch Linux, nhân 7.0.11
Bộ xử lý	AMD Ryzen 7 3750H, 8 luồng
Bộ nhớ	29 GB RAM

Toàn bộ chương trình chính gọn trong 67 dòng, sử dụng ba nhóm hàm của scikit-learn: DecisionTreeClassifier để dựng mô hình, StratifiedKFold cùng cross_val_predict để kiểm định chéo, và nhóm hàm trong sklearn.metrics để tính các chỉ số đánh giá.

4.1.2. Thực hiện khai phá dữ liệu

Chương trình được thực hiện qua các bước sau, mỗi bước có đầu vào và đầu ra rõ ràng:

Bước	Đầu vào	Đầu ra
1. Nạp dữ liệu	id = 53 từ UCI	Bảng X (150×4), cột nhãn y (150)
2. Kiểm tra chất lượng	X, y	Số liệu thiếu, trùng, ngoại lai
3. Thống kê, vẽ biểu đồ	X, y	Bảng thống kê và 4 biểu đồ
4. Khởi tạo mô hình	Bộ tham số theo Orange	Đối tượng DecisionTreeClassifier
5. Chia 10 fold phân tầng	y, seed = 42	Đối tượng StratifiedKFold
6. Kiểm định chéo	Mô hình, X, y, cv	150 nhãn và xác suất out-of-fold
7. Tính chỉ số	150 dự đoán	AUC, CA, F1, Precision, Recall, MCC
8. Dựng cây cuối cùng	Toàn bộ 150 mẫu	Cây quyết định để diễn giải

Để bảo đảm kết quả tái lập được, toàn bộ khâu có yếu tố ngẫu nhiên đều được cố định hạt giống ngẫu nhiên bằng 42. Chạy lại chương trình nhiều lần luôn cho ra cùng một kết quả.

4.1.3. Code

Toàn bộ chương trình gọn trong 67 dòng. Phần khai báo thư viện và nạp dữ liệu:

```
from ucimlrepo import fetch_ucirepo
from sklearn.tree import DecisionTreeClassifier, export_text
from sklearn.model_selection import StratifiedKFold, cross_val_predict
from sklearn.metrics import (
    accuracy_score, precision_recall_fscore_support,
    matthews_corrcoef, roc_auc_score, confusion_matrix,
)

iris = fetch_ucirepo(id=53)       # Tai bo du lieu Iris (id = 53)
X = iris.data.features            # 4 dac trung: sepal/petal length va width
y = iris.data.targets["class"]    # Nhan loai hoa
```

Chương trình hỗ trợ sẵn cách nạp dữ liệu thứ hai từ tệp CSV lưu trên máy, dùng khi không có kết nối mạng. Tệp iris.csv được tạo từ iris.data gốc của UCI và đã kiểm chứng trùng khớp hoàn toàn với dữ liệu tải trực tuyến:

```
# import pandas as pd
# df = pd.read_csv("iris.csv")
# X = df[["sepal length", "sepal width", "petal length", "petal width"]]
# y = df["class"]
```

Khởi tạo mô hình với bộ tham số lấy theo mặc định của widget Tree bên Orange:

```
model = DecisionTreeClassifier(
    criterion="gini",     # Tieu chi chia nhanh
    max_depth=100,        # Do sau toi da cua cay
    min_samples_leaf=2,   # So mau toi thieu o moi nut la
    min_samples_split=5,  # Khong tach tap nho hon 5 mau
    random_state=42,      # Co dinh de ket qua tai lap duoc
)
```

Kiểm định chéo phân tầng 10-fold. Hàm cross_val_predict trả về dự đoán out-of-fold cho cả 150 mẫu, tức mỗi mẫu đều được dự đoán bởi một mô hình chưa từng nhìn thấy nó khi huấn luyện:

```
cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
y_pred = cross_val_predict(model, X, y, cv=cv)
y_proba = cross_val_predict(model, X, y, cv=cv, method="predict_proba")
```

Tính các chỉ số đánh giá trên toàn bộ 150 dự đoán đã gộp:

```
classes = sorted(y.unique())
cm = confusion_matrix(y, y_pred, labels=classes)
prec, rec, f1, _ = precision_recall_fscore_support(y, y_pred, average="macro")
auc = roc_auc_score(y, y_proba, multi_class="ovr",
                    average="weighted", labels=classes)
```

Cuối cùng, huấn luyện lại mô hình trên toàn bộ 150 mẫu và in cấu trúc cây dưới dạng văn bản để phục vụ việc diễn giải ở Chương 5:

```
model.fit(X, y)
print(export_text(model, feature_names=list(X.columns)))
```

Chương 5. KẾT QUẢ

5.1. Kết quả khai phá dữ liệu

5.1.1. Mô hình có chính xác hay không?

Kết quả đánh giá bằng kiểm định chéo phân tầng 10-fold trên toàn bộ 150 mẫu:

Mô hình	AUC	CA	F1	Precision	Recall	MCC
Decision Tree	0.963	0.940	0.940	0.940	0.940	0.910

Độ chính xác đạt 94.0%, tương đương dự đoán đúng 141 trên 150 mẫu. Hệ số MCC đạt 0.910 trên thang tối đa là 1 — đây là chỉ số khắt khe hơn Accuracy vì có tính đến cả những dự đoán sai, nên giá trị cao như vậy khẳng định mô hình thật sự học được quy luật chứ không phải ăn may.

Kết quả chi tiết theo từng lớp:

Loài	Precision	Recall	F1	Số mẫu	Dự đoán đúng
Iris-setosa	1.000	1.000	1.000	50	50 / 50
Iris-versicolor	0.902	0.920	0.911	50	46 / 50
Iris-virginica	0.918	0.900	0.909	50	45 / 50
Trung bình macro	0.940	0.940	0.940	150	141 / 150

Ma trận nhầm lẫn, trong đó dòng là nhãn thật và cột là nhãn dự đoán:

	setosa	versicolor	virginica
setosa	50	0	0
versicolor	0	46	4
virginica	0	5	45

Ma trận cho thấy loài setosa được phân loại đúng tuyệt đối, không có mẫu nào bị nhầm. Toàn bộ chín mẫu sai đều là nhầm lẫn qua lại giữa versicolor và virginica: bốn mẫu versicolor bị đoán thành virginica và năm mẫu theo chiều ngược lại. Không có mẫu nào của hai loài này bị nhầm thành setosa.

5.1.2. Tính giải thích được của mô hình (interpretability)

Cây quyết định thu được khi huấn luyện trên toàn bộ 150 mẫu có cấu trúc như sau:

```
|--- petal length <= 2.45
|   |--- class: Iris-setosa
|--- petal length >  2.45
|   |--- petal width <= 1.75
|   |   |--- petal length <= 4.95
|   |   |   |--- sepal length <= 4.95
```

```
|   |   |   |   |--- class: Iris-versicolor
|   |   |   |--- sepal length >  4.95
|   |   |   |   |--- class: Iris-versicolor
|   |   |--- petal length >  4.95
|   |   |   |--- petal width <= 1.55
|   |   |   |   |--- class: Iris-virginica
|   |   |   |--- petal width >  1.55
|   |   |   |   |--- class: Iris-versicolor
|   |--- petal width >  1.75
|   |   |--- petal length <= 4.85
|   |   |   |--- class: Iris-virginica
|   |   |--- petal length >  4.85
|   |   |   |--- class: Iris-virginica
```

Cây có bảy nút lá, nhưng trong đó có hai phép chia là thừa — chia tiếp mà cả hai nhánh con đều cho ra cùng một nhãn. Cụ thể, phép chia theo sepal length ở mức 4.95 cho hai nhánh đều là versicolor, và phép chia theo petal length ở mức 4.85 cho hai nhánh đều là virginica. Nguyên nhân đã nêu ở mục 3.3: scikit-learn không có tham số dừng khi lớp đa số đạt 95% như widget Tree của Orange.

Sau khi lược bỏ hai nhánh thừa, cây rút gọn còn năm quy tắc if-then có ý nghĩa, đọc từ trên xuống, gặp điều kiện đúng thì dừng:

#	Điều kiện	Kết luận	Số mẫu	Độ tin cậy
1	petal length <= 2.45	setosa	50	100%
2	petal width > 1.75	virginica	46	97.8%
3	petal width <= 1.75 và petal length <= 4.95	versicolor	48	98%
4	petal length > 4.95 và petal width <= 1.55	virginica	3	100%
5	petal length > 4.95 và 1.55 < petal width <= 1.75	versicolor	3	66.7%

Điều đáng chú ý nhất là cây thực chất chỉ sử dụng hai trong bốn đặc trưng, đều là đặc trưng cánh hoa. Phép chia theo sepal length tuy có xuất hiện nhưng nằm ở nhánh thừa nên không ảnh hưởng đến kết luận. Kết quả này xác nhận đúng nhận định rút ra từ bước phân tích khám phá dữ liệu ở Chương 2.

Diễn giải bằng ngôn ngữ thường: hoa có cánh ngắn dưới 2.45 cm chắc chắn là setosa; nếu cánh dài hơn thì xét bề rộng cánh, rộng trên 1.75 cm thì gần như chắc chắn là virginica, còn hẹp hơn và cánh không quá dài thì là versicolor. Phần còn lại rơi vào vùng ranh giới với độ tin cậy chỉ khoảng hai phần ba.

Chính khả năng diễn giải này là ưu thế lớn nhất của Decision Tree so với các mô hình hộp đen. Người sử dụng cuối có thể áp dụng trực tiếp năm quy tắc trên bằng một chiếc thước đo, mà không cần đến máy tính hay hiểu biết về học máy.

5.2. So sánh kết quả thực tế với kết quả dự đoán

5.2.1. Chất lượng dữ liệu

Chất lượng dữ liệu đầu vào ảnh hưởng trực tiếp đến trần độ chính xác mà mô hình có thể đạt được. Bộ dữ liệu Iris có chất lượng tốt: đầy đủ, không thiếu giá trị, cân bằng tuyệt đối giữa ba lớp. Tuy vậy vẫn tồn tại ba hạn chế đã nêu ở Chương 2 là ba dòng trùng lặp, hai sai số đo đã biết và bốn giá trị ngoại lai.

Để kiểm chứng xem các mẫu bị phân loại sai có liên quan đến chất lượng dữ liệu hay không, chín mẫu sai đã được trích riêng ra phân tích:

petal length	petal width	Nhãn thật	Mô hình dự đoán
4.5	1.7	virginica	versicolor
4.8	1.8	versicolor	virginica
4.8	1.8	virginica	versicolor
4.9	1.5	versicolor	virginica
5.0	1.5	virginica	versicolor
5.0	1.7	versicolor	virginica
5.1	1.5	virginica	versicolor
5.1	1.6	versicolor	virginica
5.8	1.6	virginica	versicolor

Kết quả rất đáng chú ý: toàn bộ chín mẫu sai đều có chiều dài cánh hoa trong khoảng 4.5 – 5.8 cm và chiều rộng cánh hoa trong khoảng 1.5 – 1.8 cm. Không có mẫu sai nào nằm ngoài vùng này. Đối chiếu với bảng khoảng giá trị ở mục 2.3, đây chính xác là vùng chồng lấn giữa hai loài versicolor và virginica.

Trường hợp điển hình nhất nằm ở hai dòng đầu bảng: bộ dữ liệu có ba bông hoa cùng số đo cánh hoa 4.8 × 1.8 cm, trong đó một bông là versicolor và hai bông là virginica. Vì cây quyết định chỉ sử dụng hai đặc trưng cánh hoa, cả ba bông này rơi vào cùng một nút lá và buộc phải nhận cùng một nhãn — sai ít nhất một bông là điều không thể tránh khỏi.

Tuy nhiên, ba bông đó vẫn khác nhau ở số đo đài hoa, lần lượt là 5.9 × 3.2, 6.2 × 2.8 và 6.0 × 3.0. Kiểm tra toàn bộ dữ liệu cũng cho thấy không tồn tại cặp mẫu nào trùng khớp cả bốn đặc trưng mà lại khác loài. Điều này có nghĩa là về mặt lý thuyết, bộ dữ liệu vẫn phân tách được hoàn toàn nếu khai thác đủ cả bốn đặc trưng; đặc trưng đài hoa tuy gần như vô dụng trên toàn cục nhưng có thể còn chút thông tin phân biệt tại đúng vùng ranh giới này.

Kết luận rút ra: mô hình không hề dự đoán bừa. Nó chỉ sai đúng ở những chỗ mà bản thân dữ liệu thật sự mập mờ. Chín mẫu sai này phản ánh giới hạn của cách biểu diễn dữ liệu bằng hai đặc trưng cánh hoa, chứ không phải khiếm khuyết của thuật toán.

5.2.2. Nguyên lý hoạt động của thuật toán có giải quyết được vấn đề hay không?

Câu trả lời là có. Nguyên lý chia để trị của Decision Tree phù hợp với cấu trúc của bộ dữ liệu này, vì các loài hoa Iris phân tách khá rõ theo từng ngưỡng giá trị cụ thể — đúng dạng quy

luật mà cây quyết định biểu diễn được một cách tự nhiên.

Để kiểm chứng, kết quả của chương trình được đối chiếu với công cụ Orange Data Mining chạy trên cùng bộ dữ liệu và cùng cấu hình đánh giá là kiểm định chéo phân tầng 10-fold:

Nguồn kết quả	AUC	CA	F1	Precision	Recall	MCC
Chương trình (scikit-learn)	0.963	0.940	0.940	0.940	0.940	0.910
Orange Data Mining	0.963	0.933	0.933	0.934	0.933	0.900
Chênh lệch	0.000	+0.007	+0.007	+0.006	+0.007	+0.010

Chỉ số AUC trùng khớp chính xác đến ba chữ số thập phân. Các chỉ số còn lại chênh lệch 0.007, mà với 150 mẫu thì mỗi mẫu dự đoán sai làm thay đổi độ chính xác khoảng 0.67% — nghĩa là hai bên chỉ lệch nhau đúng một mẫu. Mức trùng khớp cao như vậy là điều dự đoán được, bởi Orange Data Mining cũng được xây dựng trên nền thư viện scikit-learn, về bản chất hai bên chạy cùng một cài đặt thuật toán.

Phần chênh lệch nhỏ còn lại đến từ hai nguyên nhân:

- Cách chia fold khác nhau. Orange không cho phép cố định hạt giống ngẫu nhiên, nên mười fold của Orange chắc chắn khác mười fold của chương trình vốn dùng hạt giống 42. Với tập chỉ 150 mẫu, chỉ cần một mẫu rơi vào fold khác là độ chính xác đã lệch.
- Thiếu tham số dừng ở mức 95%. Orange dừng chia nhánh khi lớp đa số tại nút đạt 95%, trong khi scikit-learn không có tham số tương đương, khiến cây của chương trình chia sâu hơn một chút và sinh ra hai nhánh thừa như đã phân tích ở mục 5.1.2.

Chương 6. THẢO LUẬN VÀ KẾT LUẬN

6.1. Thảo luận

Kết quả đề tài cho thấy một mô hình đơn giản, chỉ gồm bốn câu hỏi về kích thước cánh hoa, đã đủ để phân loại chính xác gần 95% các mẫu. Điều này gợi ra hai điểm đáng suy ngẫm.

Thứ nhất, không phải cứ nhiều đặc trưng là tốt. Bộ dữ liệu cung cấp bốn đặc trưng nhưng mô hình chỉ dùng hai. Hai đặc trưng đài hoa, đặc biệt là chiều rộng đài hoa, gần như không mang thông tin phân biệt. Nếu trong thực tế việc đo đạc tốn kém, hoàn toàn có thể bỏ qua hai số đo này mà không ảnh hưởng đến kết quả.

Thứ hai, trần độ chính xác nằm ở dữ liệu chứ không ở thuật toán. Phân tích chín mẫu sai cho thấy chúng đều nằm trong vùng chồng lấn tự nhiên giữa hai loài. Dù đổi sang thuật toán mạnh hơn cũng khó vượt qua rào cản này, bởi hai bông hoa có số đo cánh giống hệt nhau nhưng thuộc hai loài khác nhau thì về mặt toán học là không thể phân biệt được nếu chỉ dựa vào số đo đó.

Thứ ba, việc đối chiếu kết quả với một công cụ độc lập là thực hành cần thiết. Nếu chỉ chạy chương trình của mình mà không so sánh với Orange, sẽ không có cơ sở nào để khẳng định cấu hình đánh giá và cách tính chỉ số là đúng.

6.2. Ưu điểm – Nhược điểm của mô hình

6.2.1. Ưu điểm

- Dễ hiểu và dễ giải thích. Mô hình có thể trình bày dưới dạng sơ đồ cây hoặc danh sách quy tắc if-then mà người không chuyên vẫn đọc được.
- Tự động chọn đặc trưng quan trọng. Thuật toán tự loại bỏ hai đặc trưng đài hoa mà không cần người dùng can thiệp.
- Không cần chuẩn hóa dữ liệu. Do phân chia theo ngưỡng trên từng đặc trưng riêng lẻ, thuật toán không bị ảnh hưởng bởi việc các đặc trưng có đơn vị hay thang đo khác nhau.
- Ít nhạy cảm với giá trị ngoại lai so với các thuật toán dựa trên khoảng cách.
- Tốc độ dự đoán rất nhanh, chỉ cần duyệt tối đa bốn cấp từ gốc xuống lá.

6.2.2. Nhược điểm

- Dễ học vẹt (overfitting). Nếu không giới hạn độ sâu hoặc không cắt tỉa, cây sẽ phình to và học thuộc cả nhiễu trong dữ liệu huấn luyện.
- Không ổn định. Chỉ cần thay đổi một vài mẫu trong tập huấn luyện, cấu trúc cây có thể thay đổi đáng kể — điều này thể hiện rõ qua chênh lệch kết quả giữa các fold.
- Ranh giới phân chia có dạng bậc thang, vuông góc với các trục toạ độ, nên khó mô tả những ranh giới xiên hoặc cong.
- Thuật toán tham lam nên chỉ tìm được lời giải tốt cục bộ tại mỗi bước, không bảo đảm cây thu được là tối ưu toàn cục.
- Ước lượng xác suất tại nút lá khá thô, dẫn đến chỉ số AUC thấp hơn so với các mô hình

cho ra xác suất mượt hơn.

6.3. Kết luận

Đề tài đã hoàn thành mục tiêu đặt ra. Mô hình Decision Tree xây dựng bằng thư viện scikit-learn đạt độ chính xác 94.0% trên kiểm định chéo phân tầng 10-fold, với MCC 0.910 và AUC 0.963. Chương trình gọn trong 67 dòng mã.

Tính đúng đắn của cấu hình và cách tính chỉ số đã được kiểm chứng bằng cách đối chiếu với công cụ Orange Data Mining: chỉ số AUC trùng khớp chính xác, các chỉ số còn lại chỉ chênh lệch đúng một mẫu trên tổng số 150 mẫu.

Ngoài con số, đề tài còn rút ra được tri thức có giá trị sử dụng: chỉ cần hai số đo cánh hoa là đủ để phân loại, ngưỡng 2.45 cm tách được hoàn toàn loài setosa, và vùng cánh hoa dài 4.5 – 5.8 cm kết hợp rộng 1.5 – 1.8 cm là vùng mà ngay cả chuyên gia cũng khó phân biệt chắc chắn giữa versicolor và virginica.

6.4. Đề xuất

- Bổ sung đặc trưng mới. Vì trần độ chính xác nằm ở dữ liệu, hướng cải thiện hiệu quả nhất là thu thập thêm các đặc trưng khác như màu sắc, hình dạng cánh, hoặc dữ liệu di truyền, thay vì tinh chỉnh thuật toán.
- Thử các phương pháp tập hợp mô hình như Random Forest hoặc Gradient Boosting để khắc phục nhược điểm không ổn định của cây đơn lẻ.
- Áp dụng kỹ thuật cắt tỉa sau (post-pruning) và tinh chỉnh siêu tham số một cách có hệ thống thay vì dùng giá trị mặc định.
- Mở rộng quy mô dữ liệu. Với chỉ 150 mẫu, kết quả đánh giá còn dao động đáng kể giữa các lần chia fold khác nhau; tập dữ liệu lớn hơn sẽ cho đánh giá ổn định hơn.
- Kiểm định chéo lặp lại nhiều lần với các hạt giống ngẫu nhiên khác nhau, rồi lấy trung bình và độ lệch chuẩn, để có ước lượng đáng tin cậy hơn về hiệu năng thật của mô hình.

TÀI LIỆU THAM KHẢO

[1] Fisher, R. A. (1936). The Use of Multiple Measurements in Taxonomic Problems. Annals of Eugenics, 7(2), 179–188.

[2] Dua, D. and Graff, C. (2019). UCI Machine Learning Repository — Iris Data Set. University of California, Irvine. https://archive.ics.uci.edu/dataset/53/iris

[3] Breiman, L., Friedman, J., Olshen, R., Stone, C. (1984). Classification and Regression Trees. Wadsworth & Brooks.

[4] Quinlan, J. R. (1986). Induction of Decision Trees. Machine Learning, 1(1), 81–106.

[5] Gorodkin, J. (2004). Comparing two K-category assignments by a K-category correlation coefficient. Computational Biology and Chemistry, 28(5–6), 367–374.

[6] Unwin, A., Kleinman, K. (2021). The Iris data set: In search of the source of virginica. Significance, 18(6), 26–29.

[7] Demšar, J. et al. (2013). Orange: Data Mining Toolbox in Python. Journal of Machine Learning Research, 14, 2349–2353.

[8] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.